2025 模式识别
作业二

人工智能学院 221300079 王俊童

2025.3.25

221300079 王俊童，人工智能学院

1 问题一

a. 对于这个形式化问题，根据题目的描述如下:γ_{ij} 表示第 j 个样本（共 M 个被分到了第 i 类别（共 K 类）。而 μ_i 代表这个类别的均值。那很显然的一个事情是，我们的分类标准应该是类内是要尽量小的，意思是离均值点的距离应当近。因此我们的目标是，对于每一个类别都要做到这一点，那对应样本应该被分进正确的类别以达到最小，问题形式化如下：

$$\mathcal{L} = \sum_{i=1}^{K}\sum_{j=1}^{M}\gamma_{ij}\|x_j - \mu_i\|$$

那么优化函数就可以写为题目说的那个样子:

$$\arg\min_{\gamma_{ij},\mu_i}\sum_{i=1}^{K}\sum_{j=1}^{M}\gamma_{ij}\|x_j - \mu_i\| \tag{1}$$

QED，Eqn. 1

b. 根据题目描述，第一步应该是 μ_i 被固定，那么优化问题就变成了对于 M 个样本，我们要做到优化对于每个样本来说:

$$\mathcal{L}_j = \sum_{i=1}^{K}\gamma_{ij}\|x_j - \mu_i\|^2$$

要做到上述的 j 个（共 M 个式子）最小，意思是属于某一个类别。那么对于这个东西，相当于求一个

$$\arg\min_{i}\|x_j - \mu_i\|^2$$

只要找到了最小的，其他的标识变量都是 0 了。所以 γ_{ij} 可以重写为:

$$\gamma_{ij} = \begin{cases} 1, if\ dist = min_i\|x_j - \mu_i\|^2 \\ 0, otherwise. \end{cases} \tag{2}$$

对于第二步骤，其实是固定了类别之后，需要重新找一个分类的最小均值。此时问题变为:

$$\mathcal{L}_i = \sum_{j=1}^{M}\gamma_{ij}\|x_j - \mu_i\|^2$$

可以求导:

$$\frac{\partial\mathcal{L}}{\partial\mu_i} = 0$$

可以解得:

$$\mu_i = \frac{\sum_{j=1}^{M} \gamma_{ij} x_j}{\sum_{j=1}^{M} \gamma_{ij}} \tag{3}$$

所以这个题目的更新规则如 Eqn. b.,Eqn. 3所示。

c. 证明敛散性，相当于证明，新得到的 $\mathcal{L}' - \mathcal{L}$ 跟 0 的关系:
对于步骤 1，样本找到了一个新的类别，意思是找到了一个更小的均值点和他的距离，那么问题可以写为:

$$\mathcal{L}' - \mathcal{L} = \sum_{i=1}^{K} \sum_{j=1}^{M} (\gamma'_{ij} - \gamma_{ij}) \|x_j - \mu'_i\|^2$$

$$\mathcal{L}' - \mathcal{L} = \sum_{i=1}^{K} \sum_{j=1}^{M} (\|x_j - \mu'_i\|^2 - \|x_j - \mu_i\|^2) \leq 0$$

显然，根据刚才的证明，他会更小，所以一定成立。
对于步骤 2，只针对每一个类别来说，切换新的均值点，不增加计算成本，那么考虑一个类就行了:

$$\mathcal{L}' - \mathcal{L} \sim \sum_{j=1}^{M} (\|x_j - \mu'_i\|^2 - \|x_j - \mu_i\|^2)$$

$$\mathcal{L}' - \mathcal{L} \sim \sum_{j=1}^{M} (\mu_i - \mu'_i)^\top (2x_j - \mu_i - \mu'_i)$$

将 Eqn. 3带入可以化简得到:

$$\mathcal{L}' - \mathcal{L} \sim -(\mu_i - \mu'_i)^\top (\mu_i - \mu'_i) \leq 0$$

那么，根据证明，确实收敛。

2 问题二

a. 把题目说的形式带进去可以了:

$$\sum_{i=1}^{n} \epsilon_i^2 = \sum_{i=1}^{n} (y_i - \boldsymbol{x}_i^\top \beta)$$

$$\arg\min_{\beta} \sum_{i=1}^{n} (y_i - \boldsymbol{x}_i^\top \beta)$$

b. 可以写成矩阵形式的优化问题:

$$\arg\min_{\beta} (\mathbf{y} - \mathbf{X}\beta)^\top (\mathbf{y} - \mathbf{X}\beta)$$

矩阵形式的优化问题就是这样。

c. 可逆的话，那么用求导等于 0 就好了:

$$\frac{\partial \mathcal{L}}{\partial \beta} = 2\mathbf{X}^\top (\mathbf{X}\beta - \mathbf{y}) = 0$$

$$\beta^* = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

d. 因为维度 d 比 n 大, 第二问说 X 是 n*d 的, 那么 $rank(\mathbf{X}) \leq n < d$ 可以得到, 那么 $rank(\mathbf{X}^\top \mathbf{X}) \leq n < d$ 可以得到。但是，$\mathbf{X}^\top \mathbf{X}$ 这个东西是 d*d 的，所以一定不满秩。那就不可逆了

e. 在正则化项加入了之后，这个东西一般不可逆的，就可以求解了。而且一般模型都没有闭式解，这种情况下引入正则化项既降低了复杂度，也同时使得式子可以求解，这样就有闭式解了，一般为复杂度最低的，感觉也算是一种归纳偏好吧。

f. 引入正则化之后的优化目标如下:

$$\arg\min_{\beta}(\mathbf{y}-\mathbf{X}\beta)^{\top}(\mathbf{y}-\mathbf{X}\beta)+\lambda\beta^{\top}\beta$$

求导化简:

$$\frac{\partial\mathcal{L}}{\partial\beta}=2\mathbf{X}^{\top}(\mathbf{X}\beta-\mathbf{y})+2\lambda\beta=0$$

$$\beta^{*}=(\mathbf{X}^{\top}\mathbf{X}+\lambda\mathbf{I})^{-1}\mathbf{X}^{\top}\mathbf{y}$$

g. 上面说了，如果不可逆的时候，这样就解决不了了，因为没有唯一的闭式解了。但是这个东西加入之后，那个 $\lambda\mathbf{I}$ 可以让基本所有情况都可以解。这个时候就可以选择了。

h. $\lambda=0$, 就变成之前的普通线性回归,$\lambda=\infty$, 这个只能解后面的 $\beta^{\top}\beta=0$, 答案就是 0.

i. 我觉得不行，假如我们可以找到最优解 λ^{*},β^{*}，那么原来的运算可以写作:

$$(\mathbf{y}-\mathbf{X}\beta^{*})^{\top}(\mathbf{y}-\mathbf{X}\beta^{*})+\lambda^{*}\beta^{*\top}\beta^{*}$$

但是你会发现一个非常严肃的问题，当没有正则化的时候，一定存在:

$$(\mathbf{y}-\mathbf{X}\beta^{*})^{\top}(\mathbf{y}-\mathbf{X}\beta^{*})<(\mathbf{y}-\mathbf{X}\beta^{*})^{\top}(\mathbf{y}-\mathbf{X}\beta^{*})+\lambda^{*}\beta^{*\top}\beta^{*}$$

那不是，我令为 0 不就行了，所以没啥用。

3 问题三

a. 表格如下:

Table 1: Performance Metrics Table

下标	类别标记	得分	查准率	查全率	AUC-PR	AP
0	-	-	1.0000	0.0000	-	-
1	1	1.0	1.0000	0.2000	0.2000	0.2000
2	2	0.9	0.5000	0.2000	0.0000	0.0000
3	1	0.8	0.6667	0.4000	0.1167	0.1333
4	1	0.7	0.7500	0.6000	0.1417	0.1500
5	2	0.6	0.6000	0.6000	0.0000	0.0000
6	1	0.5	0.6667	0.8000	0.1267	0.1333
7	2	0.4	0.5714	0.8000	0.0000	0.0000
8	2	0.3	0.5000	0.8000	0.0000	0.0000
9	1	0.2	0.5556	1.0000	0.1056	0.1111
10	2	0.1	0.5000	1.0000	0.0000	0.0000
-	-	-	-	-	0.6907	0.7277

b. 由于 AP 的算法为

$$AP=\sum_{i=1}^{n}(r_i-r_{i-1})*p_i$$

而 AUC-PR 为:

$$AUC-PR=\sum_{i=1}^{n}(r_i-r_{i-1})*\frac{p_i+p_{i-1}}{2}$$

做个减法:

$$AP - AUC - PR = \sum_{i=1}^{n} (r_i - r_{i-1}) * \frac{p_i - p_{i-1}}{2}$$

一般情况下 $p_i \geq p_{i-1}$ 所以确实 AP 会比 AUC 大一些。

c. 我们通过计算可以得到新的 AUC 为 0.6794，新的 AP 为 0.7167. 其实就是跟先进入正样本还是负样本的顺序有区别罢了。

d. 计算得到:AUC-PR: 0.6906, AP: 0.7278. 说明我们算对了。图像如下: 代码如下:

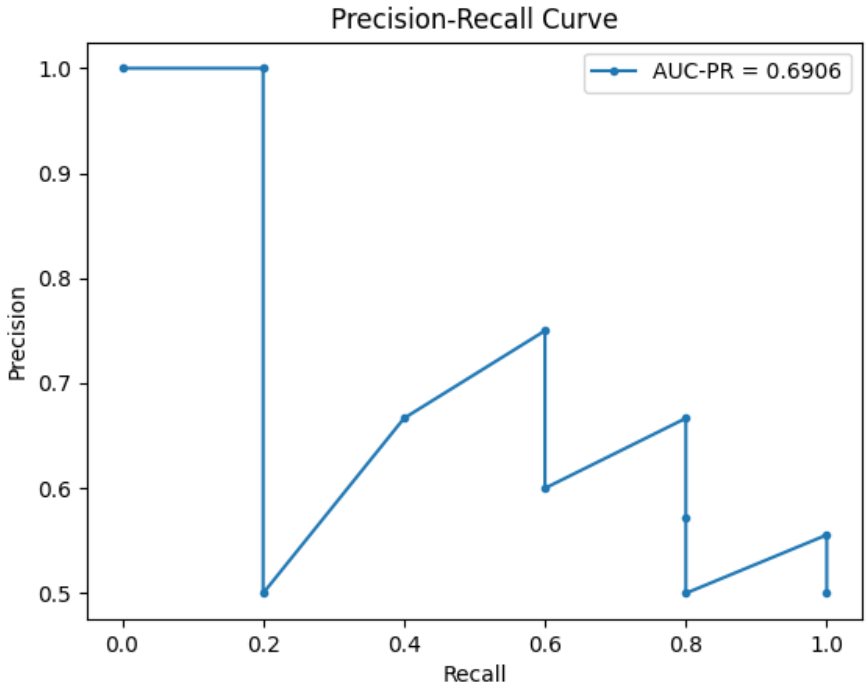

Figure 1: auc

Listing 1: Python 代码示例

```
import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import precision_recall_curve, auc, average_precision_sco

data = [
    (0, 1, 1.0),
    (1, 2, 0.9),
    (2, 1, 0.8),
    (3, 1, 0.7),
    (4, 2, 0.6),
    (5, 1, 0.5),
    (6, 2, 0.4),
    (7, 2, 0.3),
    (8, 1, 0.2),
```

```
    (9, 2, 0.1)
]

true_labels = np.array([label for _, label, _ in data])
scores = np.array([score for _, _, score in data])

binary_labels = (true_labels == 1).astype(int)
precision, recall, _ = precision_recall_curve(binary_labels, scores)
auc_pr = auc(recall, precision)
ap = average_precision_score(binary_labels, scores)

print(f"AUC-PR: {auc_pr:.4f}")
print(f"AP: {ap:.4f}")

plt.figure()
plt.plot(recall, precision, marker='.', label=f'AUC-PR = {auc_pr:.4f}')
plt.xlabel('Recall')
plt.ylabel('Precision')
plt.title('Precision-Recall Curve')
plt.legend()
plt.savefig('pr.png')
plt.show()
```

4 问题四

a. 对于这个问题，题目其实想验证一个问题，减去均值和不减去均值会对 PCA 造成什么影响。实际上，减去均值之后是对的，这样 pca 才能找到真正的变化方向。但是如果不减去均值，题目很有可能把第一主成分当作均值方向。我们可以看一下实验数据的表现。

```
Scale: 1.0000, corr1: -1.0000, corr2: 0.0373
Scale: 0.5000, corr1: -1.0000, corr2: -0.3636
Scale: 0.1000, corr1: 0.9982, corr2: 0.2976
Scale: 0.0500, corr1: 0.9924, corr2: 0.1879
Scale: 0.0100, corr1: 0.2269, corr2: 0.9921
Scale: 0.0050, corr1: 0.1261, corr2: 0.9987
Scale: 0.0010, corr1: 0.2926, corr2: 0.9999
Scale: 0.0001, corr1: 0.0672, corr2: 1.0000
```

我们可以看到，scale 很大的时候，未中心化 PCA 会使得第一主成分主要指向均值方向，这种影响最为明显。

中心化后 PCA 的主成分 new_e1 更能反映数据的真实变异方向，而不是均值的影响。可以看到这个在 scale 越小的时候，越接近 1. 可以看出正确的第一主成分 new_e1 主要由数据的协方差决定，而不是均值，因此当 scale 变小时，它的方向稳定。

通过这个题可以看出来，必须减去均值（中心化），在 scale 小的时候影响都不大的，这才是对的。不减均值那个完全就会导致整个方向错乱，甚至在 scale 大的时候，完全的被指向了与 avg 相反的方向，这是错误的。

```
rand('seed', 0);
scales = [1, 0.5, 0.1, 0.05, 0.01, 0.005, 0.001, 0.0001];
avg = [1 2 3 4 5 6 7 8 9 10];

for scale = scales
```

```
    % 生成数据
    data = randn(5000, 10) + repmat(avg * scale, 5000, 1);

    % 计算均值并归一化
    m = mean(data);
    m1 = m / norm(m);

    % PCA without centering
    [~, S, V] = svd(data);
    S = diag(S);
    e1 = V(:,1);

    % PCA with centering
    newdata = data - repmat(m, 5000, 1);
    [U, S, V] = svd(newdata);
    S = diag(S);
    new_e1 = V(:,1);

    % 计算相关性
    avg_scaled = avg - mean(avg);
    avg_scaled = avg_scaled / norm(avg_scaled);

    e1 = e1 - mean(e1);
    e1 = e1 / norm(e1);

    new_e1 = new_e1 - mean(new_e1);
    new_e1 = new_e1 / norm(new_e1);

    corr1 = avg_scaled * e1;
    corr2 = e1' * new_e1;

    % 输出结果
    fprintf('Scale: %.4f, corr1: %.4f, corr2: %.4f\n', scale, corr1, corr2);
end
```

当然，这个题还喊我们看正确的特征向量

```
Scale: 1.0000, corr1: -1.0000, corr2: -0.6733
new_e1 (first 5 values): -0.3525 -0.2847 -0.4691 0.3433 -0.2291
Scale: 0.5000, corr1: 1.0000, corr2: 0.1689
new_e1 (first 5 values): -0.1231 -0.3047 0.2140 0.1848 0.0328
Scale: 0.1000, corr1: 0.9988, corr2: -0.5822
new_e1 (first 5 values): 0.4918 0.1268 0.2494 -0.0886 0.3937
Scale: 0.0500, corr1: -0.9964, corr2: -0.4006
new_e1 (first 5 values): -0.2049 -0.4067 -0.0147 0.4926 -0.0330
Scale: 0.0100, corr1: 0.8100, corr2: 0.1957
new_e1 (first 5 values): -0.0573 -0.1757 -0.4358 -0.1678 0.7425
Scale: 0.0050, corr1: 0.2241, corr2: 0.9998
new_e1 (first 5 values): -0.5281 0.4544 -0.1225 -0.3347 0.2780
Scale: 0.0010, corr1: 0.1857, corr2: 1.0000
new_e1 (first 5 values): 0.0536 0.0390 -0.4744 0.1108 0.0601
Scale: 0.0001, corr1: 0.4436, corr2: 1.0000
new_e1 (first 5 values): -0.0259 -0.2168 -0.7334 0.0134 0.4399
```

可以看出：当 scale 较大时（如 1.0 或 0.5），new_e1 的值有较大波动。例如，在 scale = 1.0 时，new_e1 的前五个值为：-0.3525 -0.2847 -0.4691 0.3433 -0.2291。这表明均值对数据影响较大，导致主成分的方向变化较大。当 scale 较小时（如 0.0010 或 0.0001），new_e1 趋于稳定。例如，在 scale = 0.0010 时，new_e1 的前五个值为：0.0536 0.0390 -0.4744 0.1108 0.0601，这表明数据的协方差结构主导了特征向量，主成分变得更稳定